

UNIVERSIDAD TÉCNICA DE MACHALA

FACULTAD DE INGENIERÍA CIVIL

CARRERA DE TECNOLOGÍAS DE LA INFORMACIÓN

INTELIGENCIA ARTIFICIAL

Informe Clasificación de imágenes de perros y gatos con redes neuronales

CURSO

Decimo Semestre Paralelo “A”

ESTUDIANTE

Mario Sebastián Ávila León
Erick Roberto Moncada Astudillo

DOCENTE TUTOR

Ing. Sist. Rivas Asanza Wilmer Braulio, Phd.

PERIODO LECTIVO

2026 - 2

Contenido

Informe: Clasificación de imágenes de perros y gatos con redes neuronales 6

1. Resumen 6

2. Introducción y objetivos 6

3. Fundamento teórico 7

4. Datos y preprocesamiento 9

5. Modelos evaluados 10

6. Configuración experimental 12

7. Resultados del entrenamiento 13

7.1 Sin aumento de datos 15

7.2 Con aumento de datos 16

7.3 Sobreajuste y tiempo de entrenamiento 17

7.4 Estabilidad del entrenamiento 17

8. Evaluación en el conjunto de prueba 18

8.1 Errores por clase 20

8.2 Curvas ROC 21

8.3 Confianza y calibración 22

8.4 Comparación pareada entre modelos 23

9. Discusión 25

9.1 Red densa frente a red convolucional 25

9.2 Efecto del aumento de datos 25

9.3 Efecto del Dropout 26

9.4 Análisis de errores 27

9.5 Contraste de hipótesis y costo-beneficio 27

9.6 Limitaciones 29

10. Conclusiones y recomendaciones 29
11. Referencias y anexos 31
Referencias 31
Anexo A. Evolución del entrenamiento cada 10 épocas 33
Anexo B. Reproducibilidad 35

Índice de tablas

Figure 1: Ejemplos del conjunto tras el preprocesamiento (100x100, escala de grises). 10
Figure 2: Las mismas ocho imágenes con distintos niveles de aumento de datos. Los modelos "+ AD" usaron el nivel "original" (última fila). 13
Figure 3: Curvas de aprendizaje de los tres modelos sin aumento de datos. 15
Figure 4: Curvas de aprendizaje de los tres modelos con aumento de datos. 16
Figure 5: Brecha de accuracy entre entrenamiento y validación (izquierda) y tiempo de entrenamiento (derecha) 17
Figure 6: Matrices de confusión en el conjunto de prueba (filas: clase real; columnas: clase predicha). 20
Figure 7: Curvas ROC en el conjunto de prueba. 21
Figure 8: Primeras diez imágenes de prueba mal clasificadas por la CNN + AD, con la probabilidad asignada a la clase predicha 27

Índice de imágenes

Tabla 1: División del conjunto de datos. 10
Tabla 2: Arquitecturas y número de parámetros entrenables. 11
Tabla 3: Configuración común de los entrenamientos. 12
Tabla 4: Resumen del entrenamiento (100 épocas, semilla 42). La brecha es la diferencia entre el accuracy de entrenamiento y el de validación en la última época. 13
Tabla 5: Estabilidad del accuracy de validación (semilla 42). La desviación estándar es poblacional; la variación entre épocas es la desviación estándar de las diferencias entre épocas consecutivas (épocas 21 a 100). 17
Tabla 6: Métricas en el conjunto de prueba (semilla 42). La precisión y el recall por clase están en la Tabla 7. 18
Tabla 7: Aciertos y errores por clase en el conjunto de prueba (1.765 gatos y 1.725 perros). 20
Tabla 8: Confianza y accuracy en el conjunto de prueba (valores redondeados). 22
Tabla 9: Comparación pareada de las cuatro CNN en las 3.490 imágenes de prueba (prueba exacta de McNemar). 23
Tabla 10: Accuracy de prueba sin y con aumento de datos. 25

Tabla 11: Contraste de las hipótesis planteadas. 27
Tabla 12: Costo y beneficio de cada técnica (tiempos en la GPU de Colab, semilla 42). 28
Tabla 13: Accuracy de validación 33
Tabla 14: Loss de validación 33
Tabla 15: Capas de la CNN. La CNN2 agrega Dropout 0,5 antes del aplanado y usa Dense 250 (3.200.250 parámetros en esa capa; total 3.293.173). 34

Informe: Clasificación de imágenes de perros y gatos con redes neuronales

1. Resumen

La mejor combinación fue una red convolucional (CNN) entrenada con aumento de datos, que alcanzó un accuracy de 87,7 % en 3.490 imágenes de prueba que no vio durante el entrenamiento, con F1 macro de 0,877 y AUC de 0,953. Se compararon tres arquitecturas (red densa, CNN y CNN con Dropout), cada una entrenada sin y con aumento de datos, para clasificar imágenes de perros y gatos del conjunto *cats_vs_dogs* (23.262 imágenes, reducidas a 100x100 píxeles en escala de grises).

Las redes convolucionales superaron con claridad a la red densa, que no pasó de 56,2 % de accuracy y quedó cerca del azar. Sin aumento de datos, las CNN memorizaron el entrenamiento (accuracy de entrenamiento de 99,6 % y 99,5 % frente a 78,7 % y 83,9 % en validación), y el Dropout elevó el accuracy de prueba de 80,2 % a 84,7 %. Con aumento de datos desapareció el sobreajuste y la CNN subió a 87,7 %, aunque entrenar tardó unas 2,9 veces más (33,5 frente a 11,5 minutos).

Los modelos con aumento de datos seguían mejorando en la época 100, por lo que un entrenamiento más largo podría aumentar el resultado. Todas las cifras provienen de una sola corrida (semilla 42). Con 3.490 imágenes de prueba, el intervalo de confianza al 95 % del mejor accuracy es de ±1,1 puntos porcentuales; las diferencias de uno o dos puntos entre los mejores modelos deben interpretarse con cautela. La prueba de McNemar sobre las predicciones pareadas confirma que la CNN con aumento de datos supera a la CNN2 con aumento de datos (+1,9 puntos, $p = 0,001$), pero no distingue el efecto del aumento de datos sobre la CNN con Dropout (+1,1 puntos, $p = 0,15$), y no se midió la variación entre semillas.

2. Introducción y objetivos

Distinguir perros de gatos es un problema clásico de visión por computador. Las imágenes varían en pose, iluminación, fondo y tamaño, y no existe una regla simple sobre los píxeles que separe las dos clases. Por eso se resuelve con aprendizaje automático, en particular con redes neuronales entrenadas a partir de ejemplos etiquetados [1], [2].

Este trabajo mide cuánto aporta cada decisión de diseño. Se parte de una red densa como referencia, se pasa a una red convolucional y se agregan dos técnicas contra el sobreajuste, Dropout y aumento de datos, midiendo el efecto de cada una sobre imágenes que el modelo nunca vio.

Objetivo general. Comparar el desempeño de tres arquitecturas de red neuronal en la clasificación binaria de imágenes de perros y gatos.

Objetivos específicos

1. Entrenar una red densa, una CNN y una CNN con Dropout bajo las mismas condiciones y con la misma división de datos.
2. Medir el efecto del aumento de datos entrenando cada arquitectura con y sin esta técnica.
3. Evaluar los seis modelos en un conjunto de prueba independiente con accuracy, precisión, recall, F1, AUC y matriz de confusión.
4. Diagnosticar el sobreajuste a partir de las curvas de aprendizaje y analizar los errores del mejor modelo.
5. Identificar el modelo más adecuado y sus limitaciones.

Hipótesis. Antes de entrenar se plantearon tres hipótesis, que se contrastan en la sección 9.5:

- **H1.** Con un número de parámetros comparable, la CNN superará a la red densa porque aprovecha la estructura espacial de la imagen [1], [2].
- **H2.** El Dropout mejorará la generalización [3], pero su aporte será menor si ya hay otra técnica de regularización, porque ambas actúan sobre el mismo problema.
- **H3.** El aumento de datos reducirá el sobreajuste y mejorará el accuracy de prueba [4].

3. Fundamento teórico

La clasificación binaria de imágenes consiste en asignar a cada imagen una de dos clases (gato o perro) a partir de sus píxeles. Este trabajo compara tres tipos de red neuronal y dos técnicas para reducir el sobreajuste.

Red densa (perceptrón multicapa). Aplana la imagen en un vector y conecta cada píxel con cada neurona de la capa siguiente. Tiene muchos parámetros y no aprovecha que los píxeles vecinos están relacionados, por lo que suele rendir peor con imágenes.

Red convolucional (CNN). Aplica filtros pequeños (aquí de 3x3) que recorren la imagen y detectan patrones locales como bordes y texturas [1], [2]. Las capas de MaxPooling reducen el tamaño y dan tolerancia a pequeños desplazamientos. Como cada filtro comparte sus pesos en toda la imagen, necesita muchos menos parámetros que una red densa para extraer información visual.

Dropout. Durante el entrenamiento apaga al azar una fracción de las neuronas (aquí el 50 %) en cada paso. Así la red no depende de unas pocas neuronas y se reduce el sobreajuste [3].

Aumento de datos. Genera variantes de cada imagen de entrenamiento (giros, desplazamientos, zoom, cizalla y volteos) para que el modelo vea más variedad y generalice mejor [4]. Solo se aplica al conjunto de entrenamiento.

Sobreajuste. Ocurre cuando el modelo memoriza el entrenamiento y falla con datos nuevos. Se reconoce porque el accuracy de entrenamiento sigue subiendo mientras el de validación se estanca y la pérdida de validación aumenta.

Función de pérdida. Todos los modelos se entrenan con entropía cruzada binaria, donde y es la clase real (0 = gato, 1 = perro) y p la probabilidad que predice el modelo para "perro":

Optimizador y activaciones. Las capas ocultas usan ReLU y la salida una sigmoide que entrega la probabilidad de que la imagen sea un perro; se clasifica como perro si esa probabilidad es al menos 0,5. Los pesos se ajustan con Adam [5], que adapta la tasa de aprendizaje de cada parámetro a partir de estimaciones del primer y segundo momento del gradiente; aquí se usó la tasa de 0,001, el valor habitual por defecto.

Cómo leer las curvas de aprendizaje. Si el accuracy es bajo tanto en entrenamiento como en validación, el modelo subajusta: no logra aprender la tarea (caso de la red densa). Si el de entrenamiento es alto y el de validación mucho menor, sobreajusta. Si ambos son parecidos y siguen mejorando, el modelo todavía no converge y entrenar más puede ayudar (caso de los modelos con aumento de datos). Un accuracy de validación mayor que el de entrenamiento no es un error: con aumento de datos las imágenes de entrenamiento son más difíciles que las de validación, y con Dropout la red se entrena con parte de sus neuronas apagadas.

$$L = -\frac{1}{N}\sum_{i=1}^{N}[y_i \log(p_i) + (1 - y_i)\log(1 - p_i)]$$

Métricas de evaluación

- **Accuracy:** proporción de imágenes clasificadas correctamente.
- **Precisión:** de las imágenes que el modelo asigna a una clase, cuántas pertenecen realmente a ella.
- **Recall:** de las imágenes reales de una clase, cuántas detecta el modelo.
- **F1:** media armónica de precisión y recall.
- **AUC:** área bajo la curva ROC [6]. Un valor de 0,5 equivale al azar y 1,0 a una separación perfecta de las clases.
- **Matriz de confusión:** cuenta los aciertos y los errores de cada clase.

4. Datos y preprocesamiento

Se usó el conjunto *cats_vs_dogs* de TensorFlow Datasets [7], [8]: 23.262 imágenes en color y de tamaño variable, con las clases casi equilibradas (50,1 % gatos y 49,9 % perros). Por eso el accuracy es una métrica válida y un clasificador que siempre diga lo mismo ronda el 50 %.

Procedencia. Las imágenes provienen del proyecto Asirra [7], un CAPTCHA basado en fotografías de mascotas de un sitio de adopción, y se distribuyen en TensorFlow Datasets [8], cuya versión excluye las imágenes corruptas del conjunto original de 25.000 y deja las 23.262 usadas aquí. Al ser fotografías tomadas por muchas personas, tienen fondos variados, a veces más de un animal por imagen y casos ambiguos, lo que pone un techo al accuracy que se puede alcanzar.

Preprocesamiento. Cada imagen pasó por tres pasos:

1. Redimensionado a 100x100 píxeles.
2. Conversión a escala de grises (un solo canal).
3. Normalización de los píxeles del rango 0-255 al rango 0-1.

Este tratamiento reduce el costo de cómputo, pero descarta el color y parte del detalle, y el redimensionado no conserva la proporción original de la imagen. Son limitaciones que se retoman en la discusión.

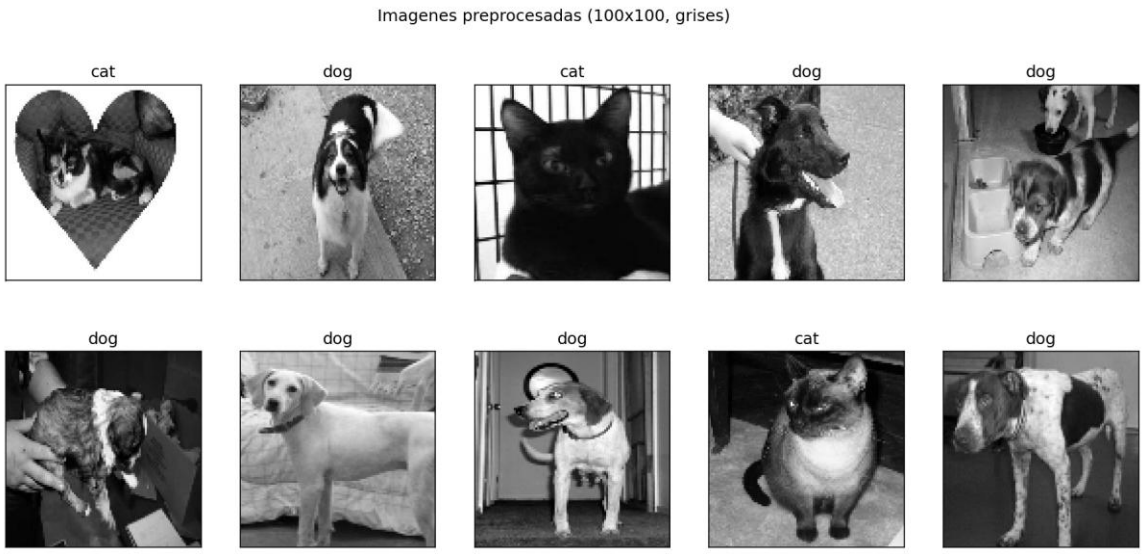


Figure 1: Ejemplos del conjunto tras el preprocesamiento (100x100, escala de grises).

División de los datos. Las imágenes se mezclaron al azar con semilla fija (42) y se repartieron en 70 % entrenamiento, 15 % validación y 15 % prueba. Los seis modelos usan exactamente las mismas imágenes en cada conjunto, de modo que la comparación es justa. El conjunto de prueba no se usó para ningún ajuste ni decisión durante el entrenamiento.

Tabla 1: División del conjunto de datos.

Conjunto	Imágenes	Gatos	Perros	Uso
Entrenamiento	16.283	8.124	8.159	Ajuste de los pesos
Validación	3.489	1.769	1.720	Seguimiento por época y diagnóstico de sobreajuste
Prueba	3.490	1.765	1.725	Evaluación final

5. Modelos evaluados

Se definieron tres arquitecturas. Cada una se entrenó dos veces, sin y con aumento de datos, lo que da seis modelos. Todas terminan en una sola neurona con activación sigmoide que entrega la

probabilidad de que la imagen sea un perro; se clasifica como perro si esa probabilidad supera 0,5.

Tabla 2: Arquitecturas y número de parámetros entrenables.

Arquitectura	Capas	Parámetros
Denso	Aplanado (10.000 entradas) → Dense 150 (ReLU) → Dense 150 (ReLU) → Dense 1 (sigmoide)	1.522.951
CNN	3 bloques de Conv 3x3 + MaxPooling 2x2 con 32, 64 y 128 filtros → Aplanado (12.800) → Dense 100 (ReLU) → Dense 1 (sigmoide)	1.372.873
CNN2 (Dropout 0,5)	Igual que la CNN, con Dropout 0,5 antes del aplanado y Dense 250 en lugar de Dense 100	3.293.173

Tres observaciones sobre el tamaño de las redes:

- La red densa y la CNN tienen un número de parámetros comparable (1,5 y 1,4 millones), por lo que la diferencia de rendimiento entre ellas no se debe a que una sea más grande, sino a cómo aprovecha la información de la imagen.
- En las CNN, casi todos los parámetros están en la capa densa posterior al aplanado: 93 % en la CNN (1.280.100 de 1.372.873) y 97 % en la CNN2 (3.200.250 de 3.293.173). Los tres bloques convolucionales suman solo unos 92.700 parámetros.
- La CNN2 se diferencia de la CNN en dos cambios a la vez, el Dropout y la capa densa más grande. Por eso su mejora o empeoramiento no puede atribuirse solo al Dropout; se retoma en la discusión.

El detalle capa por capa de la CNN, con la forma de salida y los parámetros de cada una, está en la Tabla A3 del anexo A. Cada convolución 3x3 sin relleno reduce el mapa en dos píxeles por lado y cada MaxPooling lo divide a la mitad, de modo que la imagen pasa de 100x100 a 98x98, 49x49, 47x47, 23x23, 21x21 y finalmente 10x10x128 = 12.800 valores. Esos valores entran a la capa densa de 100 neuronas, que concentra el 93,2 % de los parámetros de la CNN.

6. Configuración experimental

Los seis modelos se entrenaron con los mismos hiperparámetros. La única diferencia entre un modelo y su versión "+ AD" es el aumento de datos.

Los modelos se implementaron con Keras sobre TensorFlow [9]. Cada uno se entrenó una sola vez durante 100 épocas, y en cada época se registraron la pérdida y el accuracy de entrenamiento y de validación, que son la base de las secciones 7 y 9.

Tabla 3: Configuración común de los entrenamientos.

Parámetro	Valor
Optimizador	Adam (Adaptive Moment Estimation)
Tasa de aprendizaje	0,001
Función de pérdida	Entropía cruzada binaria
Tamaño de lote	32
Épocas	100, sin parada anticipada
Entrada	100x100, un canal, valores entre 0 y 1
Semilla	42 (división de datos y entrenamiento)
Entorno	GPU en Google Colab, TensorFlow 2.21.0

Aumento de datos. Se aplicó solo a las imágenes de entrenamiento; validación y prueba se mantuvieron intactas. En cada época el modelo ve versiones distintas de cada imagen, con giros de hasta 30°, desplazamientos horizontales y verticales de hasta 20 %, cizalla de hasta 15°, zoom entre 0,7 y 1,4 y volteos horizontal y vertical. Se mantuvo el volteo vertical del código de partida, aunque produce imágenes poco realistas (animales invertidos), como se ve en la última fila de la figura.



Figure 2: Las mismas ocho imágenes con distintos niveles de aumento de datos. Los modelos "+ AD" usaron el nivel "original" (última fila).

Evaluación. Cada modelo se evaluó con los pesos de la última época; no se restauraron los pesos de la mejor época. Esto importa para interpretar los resultados de los modelos que se degradaron o sobreajustaron durante el entrenamiento.

7. Resultados del entrenamiento

Solo los modelos con convoluciones aprendieron bien, y solo con aumento de datos dejaron de sobreajustar. Los entrenamientos completos sumaron 124,3 minutos (2 h 4 min). La tabla resume el estado de cada modelo en la última época y en su mejor momento de validación.

Tabla 4: Resumen del entrenamiento (100 épocas, semilla 42). La brecha es la diferencia entre el accuracy de entrenamiento y el de validación en la última época.

Modelo	Acc. entren. final	Acc. valid. final	Mejor acc. valid. (época)	Loss valid. final	Menor loss valid. (época)	Brecha acc. (entren. − valid.)	Tiempo (min)
Denso	54,9 %	49,8 %	60,5 %	0,691	0,662 (3)	5,1 pts	4,2

			(23)				
CNN	99,6 %	78,7 %	80,8 % (86)	2,177	0,424 (5)	20,8 pts	11,5
CNN2 (Dropout 0,5)	99,5 %	83,9 %	85,1 % (72)	0,990	0,372 (8)	15,6 pts	12,1
Denso + AD	55,6 %	54,5 %	54,9 % (95)	0,686	0,684 (99)	1,1 pts	29,2
CNN + AD	84,0 %	88,1 %	88,1 % (100)	0,278	0,278 (100)	−4,0 pts	33,5
CNN2 (Dropout 0,5) + AD	81,3 %	85,2 %	86,5 % (91)	0,339	0,320 (98)	−3,8 pts	33,8

7.1 Sin aumento de datos

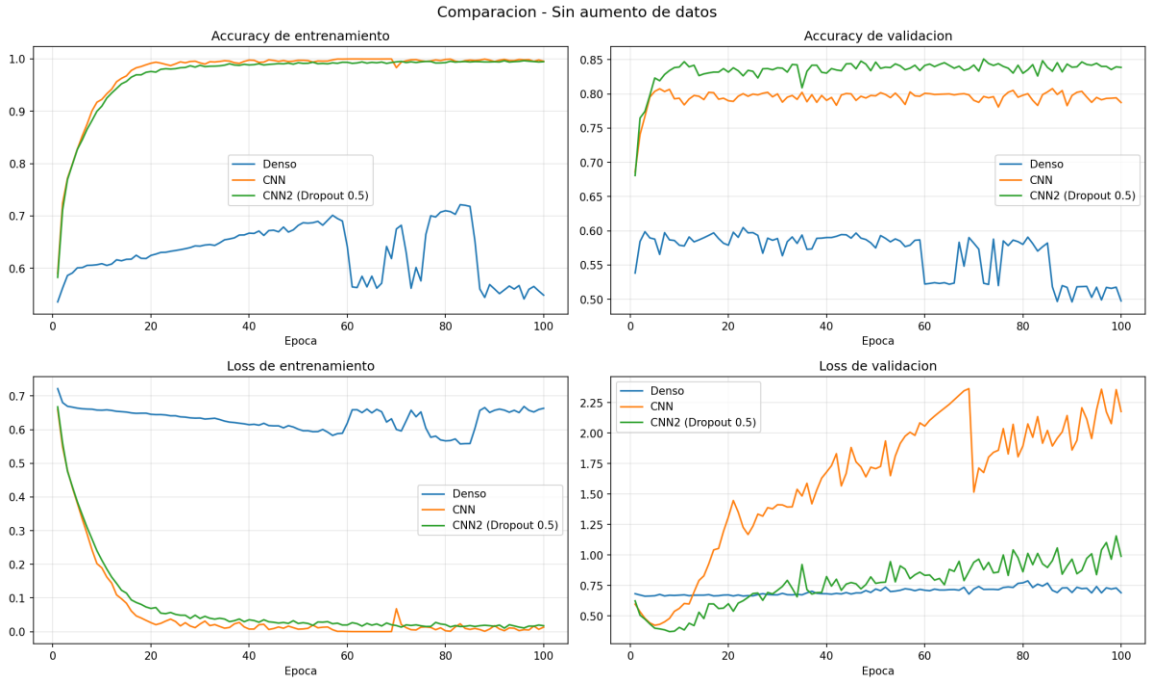


Figure 3: Curvas de aprendizaje de los tres modelos sin aumento de datos.

- **Denso.** Aprende poco y de forma inestable. El accuracy de validación no pasó de 60,5 % (época 23). A partir de la época 60 el entrenamiento se vuelve errático: el accuracy de entrenamiento llegó a 71,0 % en la época 80 y cayó a 56,0 % en la 90, y la validación terminó en 49,8 %. No se investigó la causa; es compatible con inestabilidad del optimizador, y se retoma en la discusión.
- **CNN.** Aprende rápido (79,4 % de accuracy de validación en la época 10) pero memoriza el entrenamiento: desde la época 20 su accuracy de entrenamiento ronda el 99 % o más mientras el de validación queda cerca de 80 %. La loss de validación es mínima en la época 5 (0,424) y sube hasta 2,177 en la época 100, unas 5 veces más. Es un caso claro de sobreajuste.
- **CNN2 (Dropout).** También alcanza 99,5 % en entrenamiento, pero su validación se mantiene más alta (en general entre 83 % y 85 %) y su loss de validación crece menos: de 0,372 en la época 8 a 0,990 en la 100. El Dropout reduce el sobreajuste, pero no lo elimina.

7.2 Con aumento de datos

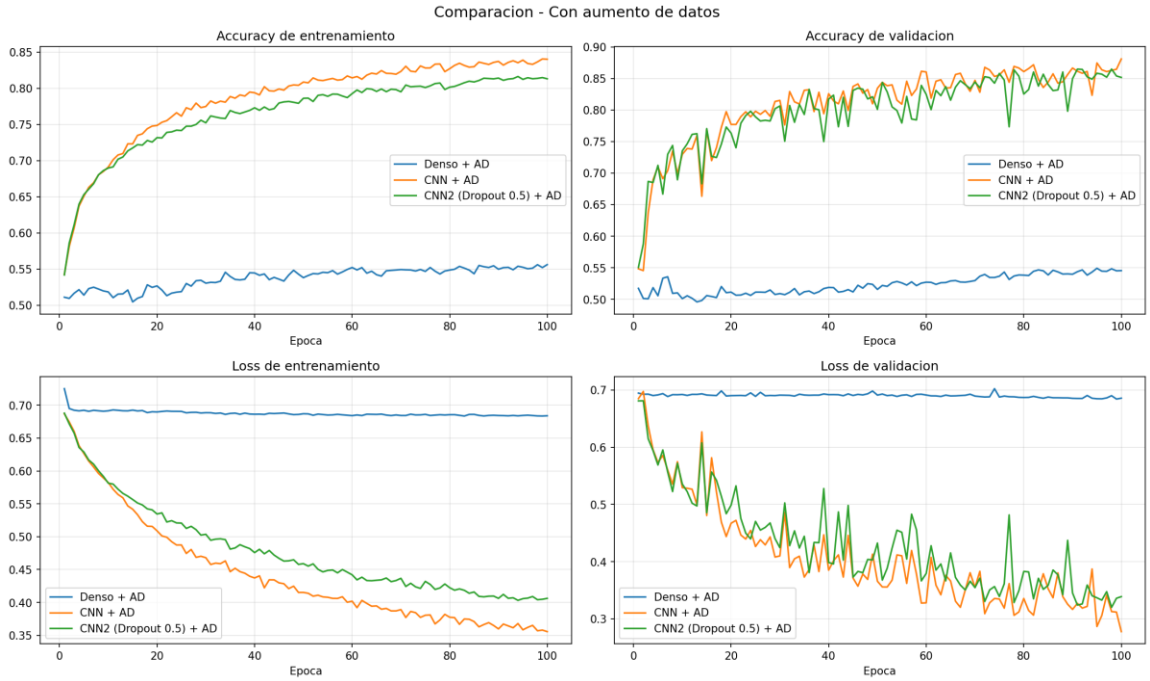


Figure 4: Curvas de aprendizaje de los tres modelos con aumento de datos.

- **Denso + AD.** Casi no aprende: su accuracy de entrenamiento es 55,6 % y su loss queda en 0,684, cerca de 0,693, el valor de adivinar al azar entre dos clases. No hay sobreajuste porque tampoco hay aprendizaje (subajuste).
- **CNN + AD y CNN2 + AD.** Mejoran de forma sostenida: el accuracy de validación pasa de 54,8 % y 55,1 % en la época 1 a 88,1 % y 85,2 % en la 100. Su mejor época de validación está al final del entrenamiento (épocas 100 y 91), así que no habían convergido.
- **Brecha negativa.** El accuracy de entrenamiento es menor que el de validación (−4,0 y −3,8 puntos). Es esperable: el entrenamiento se mide sobre imágenes transformadas, más difíciles, y en la CNN2 con el Dropout activo, mientras que la validación usa imágenes originales.
- **Ruido.** La validación oscila varios puntos de una época a otra, por lo que el valor de una sola época es poco fiable.
- **Dropout más aumento de datos.** La CNN2 + AD aprende más lento que la CNN + AD (81,3 % frente a 84,0 % en entrenamiento y 85,2 % frente a 88,1 % en validación en la

época 100). Es compatible con que dos regularizadores juntos sean excesivos para 100 épocas.

7.3 Sobreajuste y tiempo de entrenamiento

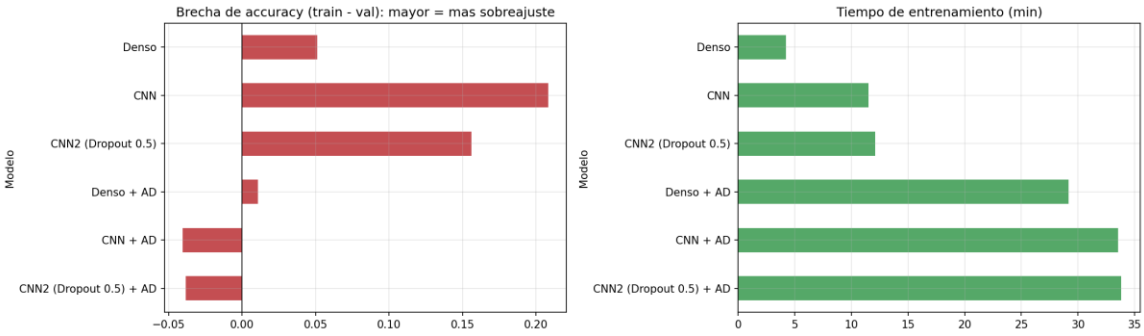


Figure 5: Brecha de accuracy entre entrenamiento y validación (izquierda) y tiempo de entrenamiento (derecha).

La brecha confirma el diagnóstico: 20,8 puntos en la CNN y 15,6 en la CNN2 sin aumento de datos, y valores negativos con aumento de datos. El aumento de datos cuesta tiempo: los modelos con él tardaron entre 2,8 y 7 veces más (29 a 34 minutos frente a 4 a 12), principalmente por generar las imágenes transformadas en cada época.

7.4 Estabilidad del entrenamiento

Más allá del valor final, importa cuánto fluctúa el accuracy de validación entre épocas, porque indica cuánto depende el resultado de la época en que se detiene el entrenamiento. La Tabla 5 resume las últimas 10 épocas y la variación entre épocas consecutivas desde la época 21.

Tabla 5: Estabilidad del accuracy de validación (semilla 42). La desviación estándar es poblacional; la variación entre épocas es la desviación estándar de las diferencias entre épocas consecutivas (épocas 21 a 100).

Modelo	Media (últimas 10 épocas)	Desv. est. (últimas 10)	Variación entre épocas (desv. est.)	Valor en la época 100
Denso	51,2 %	0,8 pts	2,2 pts	49,8 %
CNN	79,4 %	0,5 pts	0,8 pts	78,7 %
CNN2 (Dropout 0,5)	84,1 %	0,3 pts	0,9 pts	83,9 %

Denso + AD	54,5 %	0,3 pts	0,4 pts	54,5 %
CNN + AD	86,1 %	1,4 pts	2,0 pts	88,1 %
CNN2 (Dropout 0,5) + AD	85,7 %	0,6 pts	2,9 pts	85,2 %

Tres lecturas:

- **Los modelos sin aumento de datos parecen estables, pero por estancamiento.** Fluctúan poco (0,8 a 0,9 puntos entre épocas en las CNN) porque ya memorizaron el entrenamiento y sus pesos casi no cambian; la estabilidad no indica buena generalización.
- **Con aumento de datos el accuracy de validación es más ruidoso** (2,0 y 2,9 puntos entre épocas en las CNN). Es esperable: en cada época la red ve imágenes distintas y sigue ajustando sus pesos con la misma tasa de aprendizaje.
- **El valor final de la CNN + AD es favorable.** Su accuracy de validación en la época 100 (88,1 %) es el mejor de todo el entrenamiento y queda unos 2 puntos sobre la media de las últimas 10 épocas (86,1 %). El accuracy de prueba se midió solo en la época 100; si la validación es una guía, un modelo detenido en otra de las últimas épocas habría rendido más cerca de 86 % que de 87,7 %. Esta variación por época es una fuente de incertidumbre adicional a la del muestreo de las imágenes de prueba.

8. Evaluación en el conjunto de prueba

La CNN con aumento de datos obtuvo el mejor resultado en las 3.490 imágenes de prueba: 87,7 % de accuracy, F1 macro de 0,877 y AUC de 0,953. La tabla ordena los modelos por accuracy; el intervalo de confianza del 95 % se calculó con la aproximación normal de una proporción.

Tabla 6: Métricas en el conjunto de prueba (semilla 42). La precisión y el recall por clase están en la Tabla 7.

Modelo	Accuracy (IC 95 %)	Loss	F1 macro	AUC
CNN + AD	87,7 % (±1,1)	0,287	0,877	0,953

CNN2 (Dropout 0,5) + AD	85,8 % (±1,2)	0,334	0,858	0,935
CNN2 (Dropout 0,5)	84,7 % (±1,2)	0,843	0,847	0,923
CNN	80,2 % (±1,3)	1,605	0,801	0,885
Denso + AD	56,2 % (±1,6)	0,683	0,562	0,577
Denso	49,8 % (±1,7)	0,692	0,338	0,503

Tres lecturas de la tabla:

- **Coherencia con la validación.** El accuracy de prueba difiere del de validación final en menos de 1,7 puntos en todos los modelos, así que la validación daba una estimación fiable.
- **La loss revela el sobreajuste.** La CNN sin aumento de datos tiene 80,2 % de accuracy pero una loss de 1,605, casi 6 veces la de la CNN con aumento de datos (0,287). Sus errores son pocos, pero cometidos con mucha confianza, consecuencia de haber memorizado el entrenamiento.
- **El F1 macro desenmascara a la red densa.** El modelo Denso tiene accuracy de 49,8 % y una precisión macro de 0,748, pero su F1 macro es 0,338. Predice "perro" para 3.478 de las 3.490 imágenes, así que se comporta como un clasificador constante.

8.1 Errores por clase

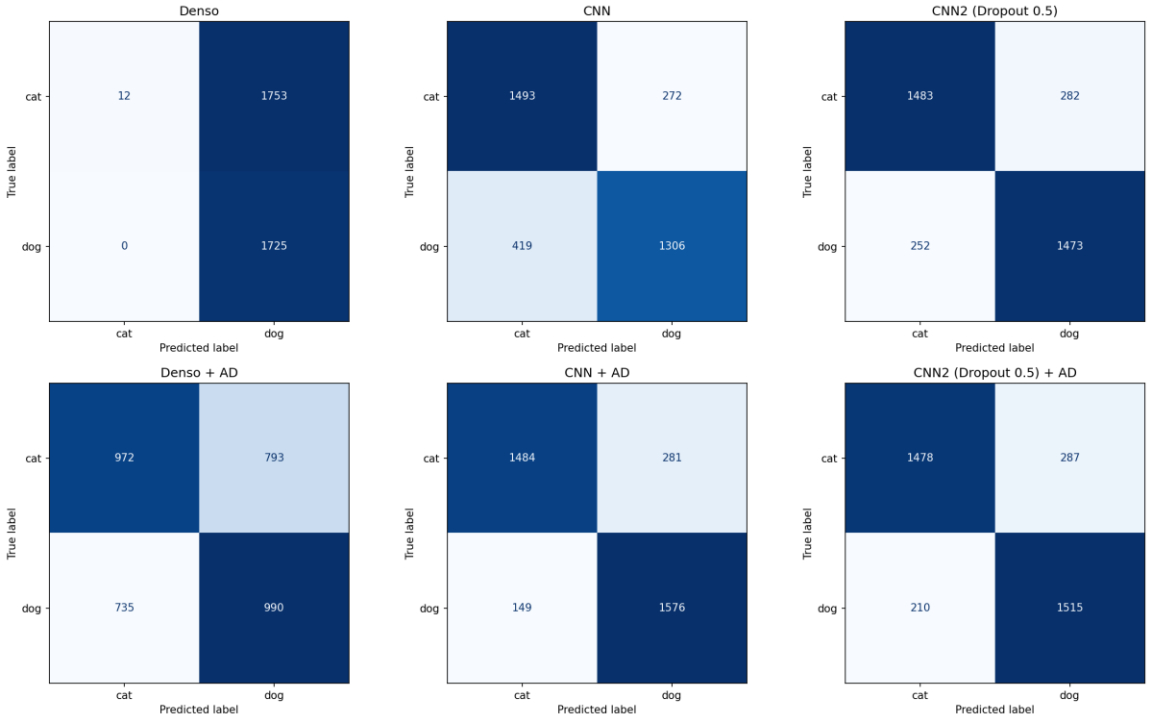


Figure 6: Matrices de confusión en el conjunto de prueba (filas: clase real; columnas: clase predicha).

Tabla 7: Aciertos y errores por clase en el conjunto de prueba (1.765 gatos y 1.725 perros).

Modelo	Gatos bien (recall)	Perros bien (recall)	Gato → perro	Perro → gato
CNN + AD	1.484 (84,1 %)	1.576 (91,4 %)	281	149
CNN2 (Dropout 0,5) + AD	1.478 (83,7 %)	1.515 (87,8 %)	287	210
CNN2 (Dropout 0,5)	1.483 (84,0 %)	1.473 (85,4 %)	282	252
CNN	1.493 (84,6 %)	1.306 (75,7 %)	272	419
Denso + AD	972 (55,1 %)	990 (57,4 %)	793	735
Denso	12 (0,7 %)	1.725 (100 %)	1.753	0

El mejor modelo cometió 430 errores en 3.490 imágenes (12,3 %): 281 gatos clasificados como perro y 149 perros como gato. Detecta mejor a los perros (91,4 %) que a los gatos (84,1 %), es decir, tiende a decir "perro" ante la duda. La CNN sin aumento de datos muestra el sesgo contrario, con más perros clasificados como gato (419) que gatos como perro (272).

8.2 Curvas ROC

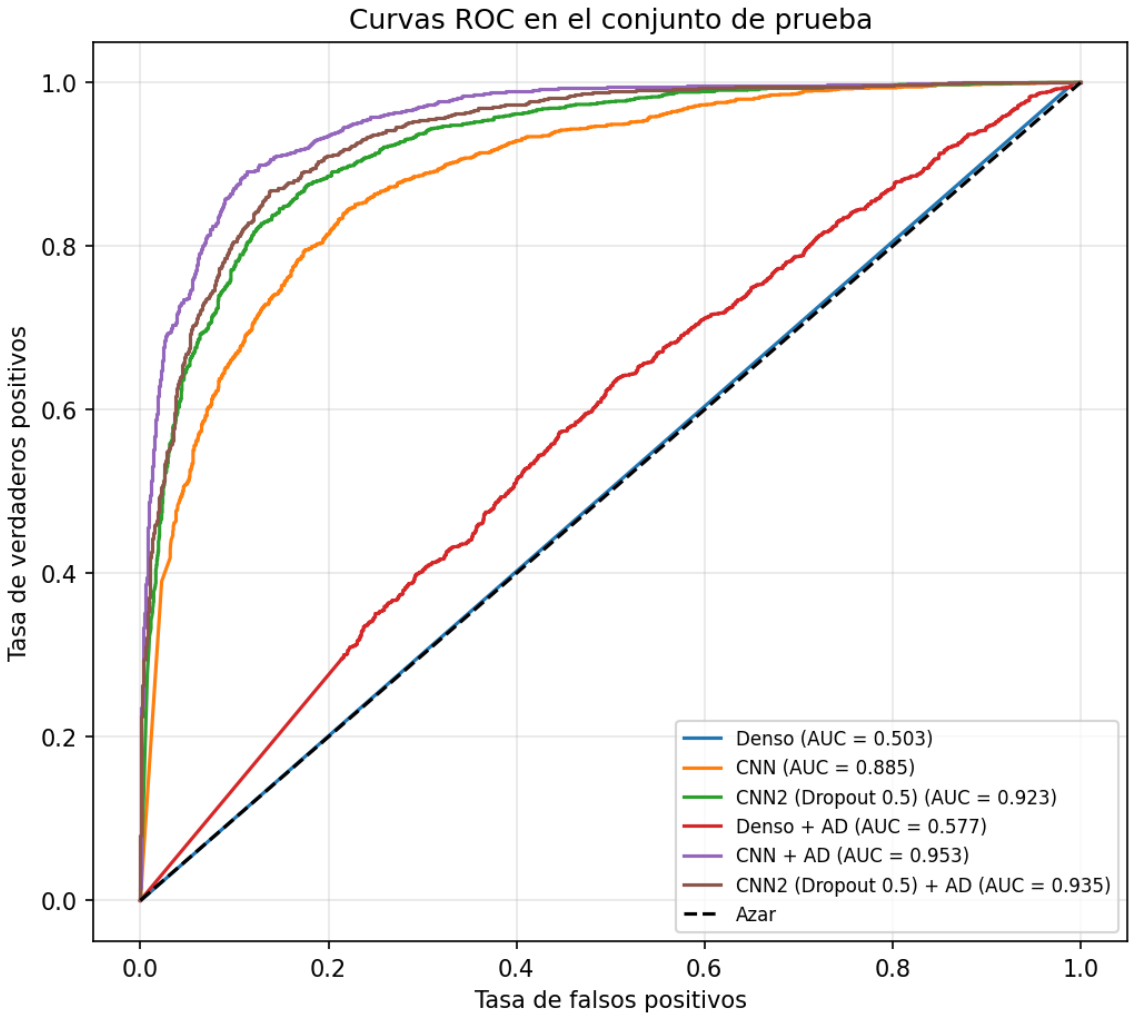


Figure 7: Curvas ROC en el conjunto de prueba.

La curva ROC no depende del umbral de 0,5 y confirma el orden de los modelos. Las cuatro CNN quedan muy por encima de la diagonal del azar, y la curva de la red densa sin aumento de datos coincide con ella (AUC de 0,503). La red densa con aumento de datos mejora apenas (AUC de 0,577).

8.3 Confianza y calibración

Un buen clasificador no solo acierta: su confianza debe reflejar cuánto puede acertar [10]. Como confianza de cada predicción se usó la probabilidad de la clase elegida (el mayor entre p y 1 − p). La Tabla 8 compara la confianza media con el accuracy real; una confianza mayor que el accuracy indica exceso de confianza.

Tabla 8: Confianza y accuracy en el conjunto de prueba (valores redondeados).

Modelo	Confianza media	Accuracy	Diferencia	Predicciones con confianza > 0,99	Predicciones con confianza < 0,7
CNN + AD	89,2 %	87,7 %	+1,5 pts	32,3 %	13,2 %
CNN2 (Dropout 0,5) + AD	82,4 %	85,8 %	−3,4 pts	12,0 %	24,5 %
CNN2 (Dropout 0,5)	96,5 %	84,7 %	+11,8 pts	76,8 %	4,4 %
CNN	97,6 %	80,2 %	+17,4 pts	84,2 %	2,8 %
Denso + AD	55,8 %	56,2 %	−0,4 pts	0,0 %	96,9 %
Denso	50,7 %	49,8 %	+0,9 pts	0,1 %	99,7 %

- **Las CNN sin aumento de datos tienen un exceso grande de confianza.** La CNN da más de 99 % de confianza al 84,2 % de las imágenes, pero acierta el 80,2 %; por lo tanto, al menos 4 % de las imágenes de prueba (unas 140) son errores cometidos con más de 99 % de confianza. Esto es coherente con su loss de prueba de 1,605 (sección 8), que castiga con dureza los errores muy seguros.

- **El aumento de datos corrige la confianza.** La CNN + AD queda a 1,5 puntos de su accuracy y su loss de prueba es de 0,287. La CNN2 + AD tiene un leve defecto de confianza (−3,4 puntos), compatible con el efecto conjunto de Dropout y aumento de datos.
- **En la red densa la confianza baja es coherente con el azar,** pero no aporta información útil: casi todas sus predicciones están entre 0,5 y 0,7.

Esta comparación es global. Un diagrama de fiabilidad por intervalos y el error de calibración esperado (ECE) requieren la etiqueta de cada imagen de prueba, que no se guardó junto con las probabilidades; queda como ampliación.

8.4 Comparación pareada entre modelos

Los intervalos de confianza de la Tabla 6 se solapan entre los mejores modelos, pero comparar intervalos por separado pierde potencia porque todos los modelos se evaluaron sobre las mismas imágenes. La prueba de McNemar [11] compara dos clasificadores usando solo las imágenes en que discrepan. En una clasificación binaria, si dos modelos dan predicciones distintas para una imagen, exactamente uno acierta; por eso el número de discrepancias sale de las predicciones guardadas y la diferencia de aciertos, de las matrices de confusión. Se aplicó la versión exacta (binomial) a seis comparaciones entre las CNN (Tabla 9); el intervalo de la diferencia usa la aproximación normal para muestras pareadas.

Tabla 9: Comparación pareada de las cuatro CNN en las 3.490 imágenes de prueba (prueba exacta de McNemar).

A frente a B	Solo A acierta	Solo B acierta	Ambos fallan	Discrepan	Diferencia A − B (IC 95 %)	p
CNN + AD frente a CNN2 + AD	236	169	261	405 (11,6 %)	+1,9 pts (0,8 a 3,1)	0,001
CNN2 frente a	396	239	295	635 (18,2 %)	+4,5 pts (3,1 a 5,9)	< 0,001

CNN						
CNN2 + AD frente a CNN2	331	294	203	625 (17,9 %)	+1,1 pts (−0,3 a 2,5)	0,15
CNN + AD frente a CNN2	347	243	187	590 (16,9 %)	+3,0 pts (1,6 a 4,3)	< 0,001
CNN + AD frente a CNN	515	254	176	769 (22,0 %)	+7,5 pts (5,9 a 9,0)	< 0,001
CNN2 + AD frente a CNN	507	313	184	820 (23,5 %)	+5,6 pts (4,0 a 7,2)	< 0,001

- **El Dropout sin aumento de datos es una mejora clara.** La CNN2 acierta 396 imágenes que falla la CNN y esta solo 239 que falla la CNN2 (+4,5 puntos, $p < 0,001$).
- **El aumento de datos ayuda mucho a la CNN y poco a la CNN2.** En la CNN la mejora es de +7,5 puntos ($p < 0,001$); en la CNN2 es de +1,1 puntos y el intervalo incluye el cero ($p = 0,15$), así que no se distingue del azar.
- **La ventaja de la CNN + AD sobre la CNN2 + AD es pequeña pero real en esta corrida.** Los modelos discrepan en 405 imágenes y la ventaja neta es de 67 (+1,9 puntos, $p = 0,001$), que sigue siendo significativa con la corrección de Bonferroni para seis comparaciones (umbral $0,05 / 6 \approx 0,008$).
- **Hay un núcleo de imágenes difíciles.** Las dos mejores CNN fallan juntas en 261 imágenes (7,5 % del conjunto), más de la mitad de los errores de cada una (60,7 % de los de la CNN + AD y 52,5 % de los de la CNN2 + AD). Es probable que sean imágenes ambiguas o difíciles a 100x100 en escala de grises, que no se resuelven cambiando la regularización.

Estas pruebas tratan cada modelo entrenado como fijo: miden el azar del muestreo de las imágenes de prueba, no cuánto cambiaría el resultado al repetir el entrenamiento con otra semilla.

9. Discusión

Lo que más influyó en el resultado fue el tipo de red; lo segundo, el aumento de datos. El Dropout aportó poco, y su efecto depende de si hay otra técnica de regularización.

9.1 Red densa frente a red convolucional

Con un número de parámetros comparable (1,5 y 1,4 millones), la red densa quedó cerca del azar (49,8 % y 56,2 %) y la CNN llegó a 80,2 % sin aumento de datos. La red densa aplana la imagen y trata cada píxel como una variable independiente, perdiendo la relación entre píxeles vecinos. Los filtros convolucionales, en cambio, detectan el mismo patrón (un borde, una textura, una oreja) en cualquier posición de la imagen.

El entrenamiento de la red densa también fue inestable (sección 7.1), y su mejor accuracy de validación fue 60,5 % en la época 23. Con otros hiperparámetros o con parada anticipada podría acercarse a ese valor, pero seguiría muy por debajo de las CNN.

9.2 Efecto del aumento de datos

Tabla 10: Accuracy de prueba sin y con aumento de datos.

Arquitectura	Sin aumento de datos	Con aumento de datos	Cambio
Denso	49,8 %	56,2 %	+6,4 pts
CNN	80,2 %	87,7 %	+7,5 pts
CNN2 (Dropout 0,5)	84,7 %	85,8 %	+1,1 pts

La mejora fue mayor donde el sobreajuste era mayor. En la CNN, el aumento de datos eliminó la memorización: la loss de prueba bajó de 1,605 a 0,287 y la brecha entre entrenamiento y

validación pasó de 20,8 puntos a −4,0. En la CNN2, que ya estaba regularizada por el Dropout, la ganancia fue de solo 1,1 puntos, menor que el intervalo de confianza de la medición (±1,2).

El costo fue el tiempo de cómputo (unas 2,9 veces más en la CNN). Además, los modelos con aumento de datos seguían mejorando al final del entrenamiento, así que su resultado probablemente subestima lo que lograrían con más épocas. No se probó si un aumento más suave, sin volteo vertical, aprendería más rápido.

9.3 Efecto del Dropout

Sin aumento de datos, la CNN2 mejoró a la CNN en 4,5 puntos de accuracy de prueba (84,7 % frente a 80,2 %), redujo la loss de prueba de 1,605 a 0,843 y la brecha de 20,8 a 15,6 puntos. Con aumento de datos ocurrió lo contrario: la CNN2 + AD quedó 1,9 puntos por debajo de la CNN + AD (85,8 % frente a 87,7 %). La lectura más razonable es que el Dropout ayuda cuando el modelo no tiene otra defensa contra el sobreajuste, pero junto con el aumento de datos ralentiza el aprendizaje en 100 épocas.

Hay dos reservas. Primero, la CNN2 no solo agrega Dropout, también usa una capa densa de 250 neuronas en lugar de 100, así que no se puede atribuir la diferencia solo al Dropout. Segundo, cada modelo se entrenó una vez: la diferencia de 1,9 puntos es algo mayor que el margen de error de cada medición (±1,1 y ±1,2). La prueba de McNemar [11] sobre las predicciones pareadas (sección 8.4) indica que no se explica solo por el azar del muestreo del conjunto de prueba ($p = 0,001$), pero esa prueba no mide cuánto varía el resultado entre semillas distintas, que no se evaluó.

9.4 Análisis de errores

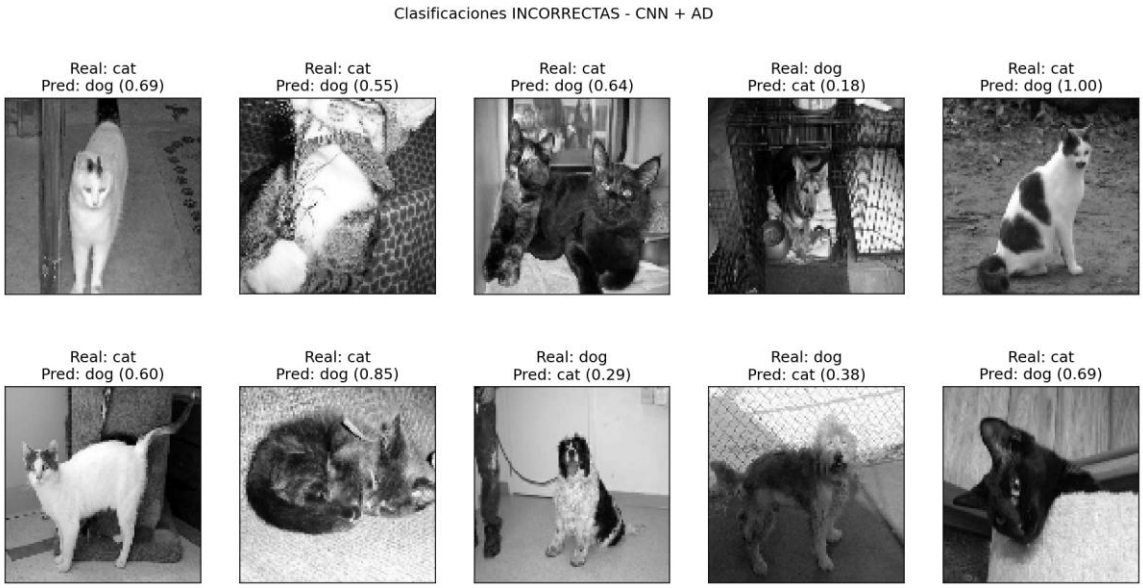


Figure 8: Primeras diez imágenes de prueba mal clasificadas por la CNN + AD, con la probabilidad asignada a la clase predicha

Siete de las diez imágenes de la figura son gatos clasificados como perro, coherente con el sesgo hacia "perro" visto en la matriz de confusión. Entre los errores hay gatos acostados o enroscados, de pelaje muy oscuro o muy claro, fondos con mucha textura (alfombras, sofás, rejas) y perros peludos detrás de una reja. Un gato sentado al aire libre fue clasificado como perro con probabilidad 1,00, un error con máxima confianza. Con imágenes de 100x100 en grises se pierden detalles como el color del pelaje o la forma fina del hocico, lo que puede explicar parte de estos fallos.

9.5 Contraste de hipótesis y costo-beneficio

La Tabla 11 contrasta las hipótesis de la sección 2 con la evidencia de las secciones 7 y 8.

Tabla 11: Contraste de las hipótesis planteadas.

Hipótesis	Evidencia	Conclusión
H1. La CNN supera a la red densa	80,2 % frente a 49,8 % sin aumento de datos; 87,7 % frente a 56,2 % con aumento de datos	Confirmada

H2. El Dropout mejora la generalización, menos si hay otra regularización	+4,5 puntos sin aumento de datos ($p < 0,001$); −1,9 con aumento de datos ($p = 0,001$)	Confirmada sin aumento de datos; con aumento de datos no ayudó en 100 épocas, con la reserva de que la CNN2 también cambia la capa densa
H3. El aumento de datos reduce el sobreajuste y mejora el accuracy	Brecha de 20,8 a −4,0 puntos y +7,5 puntos en la CNN ($p < 0,001$); +1,1 puntos en la CNN2 ($p = 0,15$)	Confirmada en la CNN; no concluyente en la CNN2

La Tabla 12 pone el beneficio en relación con el tiempo de entrenamiento, tomando como base la CNN sin Dropout ni aumento de datos.

Tabla 12: Costo y beneficio de cada técnica (tiempos en la GPU de Colab, semilla 42).

Modelo	Accuracy de prueba	Tiempo (min)	Ganancia frente a la CNN	Tiempo adicional
CNN	80,2 %	11,5	—	—
CNN2 (Dropout 0,5)	84,7 %	12,1	+4,5 pts	+0,6 min
CNN + AD	87,7 %	33,5	+7,5 pts	+22,0 min
CNN2 (Dropout 0,5) + AD	85,8 %	33,8	+5,6 pts	+22,3 min

El Dropout, junto con el cambio de capa densa, dio 4,5 puntos por menos de un minuto adicional, la mejor relación de todo el estudio. El aumento de datos dio más (7,5 puntos) pero con casi el triple de tiempo, probablemente porque las imágenes transformadas se generan en cada época (no se midió por separado). En la red densa el aumento de datos no valió la pena: el tiempo pasó de 4,2 a 29,2 minutos, unas 7 veces más, y el modelo siguió cerca del azar. En la

práctica: con poco tiempo de cómputo, la CNN2 sin aumento de datos (84,7 %) es una opción razonable; para el mejor resultado, la CNN con aumento de datos, y entrenarla más épocas costaría aún más tiempo.

9.6 Limitaciones

- **Una sola corrida por modelo** (semilla 42). La prueba de McNemar solo cuantifica el azar del muestreo de las imágenes de prueba (con una prueba por comparación, sin corrección por comparaciones múltiples), no la variación por semilla. La diferencia entre CNN2 + AD y CNN2 (1,1 puntos, p = 0,15) no es distinguible del azar, y la de CNN + AD frente a CNN2 + AD (1,9 puntos) debe confirmarse con varias semillas.
- **Entrada reducida:** 100x100, escala de grises y proporción deformada.
- **Sin parada anticipada ni restauración de los mejores pesos.** Los modelos sin aumento de datos se evaluaron tras sobreajustar: su loss de validación era mínima en las épocas 5 y 8.
- **Modelos con aumento de datos sin converger** a las 100 épocas.
- **Comparación CNN y CNN2 con dos cambios a la vez** (Dropout y tamaño de la capa densa).
- **Volteo vertical en el aumento de datos,** que genera imágenes poco realistas.
- **Hiperparámetros sin ajustar:** se usó la misma tasa de aprendizaje y el mismo lote para todos.

10. Conclusiones y recomendaciones

El modelo recomendado es la CNN con aumento de datos, con 87,7 % de accuracy en prueba, el menor error y la menor loss de los seis, sin sobreajuste. Su ventaja sobre la CNN2 con aumento de datos (1,9 puntos) es significativa en esta corrida (McNemar, p = 0,001), pero debe confirmarse con varias semillas.

Conclusiones

1. Las convoluciones fueron decisivas. Las cuatro CNN lograron entre 80,2 % y 87,7 % de accuracy en prueba; la red densa, 49,8 % y 56,2 %, cerca del azar.

2. Sin aumento de datos, las CNN sobreajustaron: llegaron a 99,6 % y 99,5 % en entrenamiento, pero solo a 78,7 % y 83,9 % en validación, con brechas de 20,8 y 15,6 puntos.
3. El aumento de datos fue la técnica más eficaz. Elevó la CNN de 80,2 % a 87,7 %, eliminó la brecha y redujo la loss de prueba de 1,605 a 0,287, a cambio de entrenar unas 2,9 veces más lento.
4. El Dropout ayudó sin aumento de datos (+4,5 puntos), pero no con aumento de datos (−1,9 puntos); además, esa comparación mezcla el Dropout con una capa densa más grande.
5. El mejor modelo comete 430 errores en 3.490 imágenes (12,3 %) y tiende a clasificar gatos como perros (281 frente a 149).

Recomendaciones

1. Entrenar los modelos con aumento de datos más allá de 100 épocas, con parada anticipada y restauración de los mejores pesos [12], y aplicar esa misma parada a los modelos sin aumento de datos.
2. Repetir los entrenamientos con tres a cinco semillas y reportar media y desviación estándar, para confirmar las diferencias pequeñas, y guardar las etiquetas de prueba junto con las probabilidades para calcular el error de calibración esperado (ECE) [10].
3. Aislar el efecto del Dropout comparando la CNN con una capa densa de 250 neuronas con y sin Dropout.
4. Probar un aumento de datos más suave y sin volteo vertical.
5. Usar imágenes en color y mayor resolución (por ejemplo, 128x128), y añadir BatchNormalization [13].
6. Incluir una red preentrenada (por ejemplo, MobileNetV2 con transfer learning [14]) como referencia superior.
7. Si se quiere comparar la red densa de forma justa, entrenarla con una tasa de aprendizaje menor y parada anticipada.

11. Referencias y anexos

Referencias

[1] Y. LeCun, Y. Bengio y G. Hinton, "Deep learning," *Nature*, vol. 521, no. 7553, pp. 436–444, 2015, doi: 10.1038/nature14539.

[2] I. Goodfellow, Y. Bengio y A. Courville, *Deep Learning*. Cambridge, MA, EE. UU.: MIT Press, 2016.

[3] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever y R. Salakhutdinov, "Dropout: A simple way to prevent neural networks from overfitting," *J. Mach. Learn. Res.*, vol. 15, no. 56, pp. 1929–1958, 2014.

[4] C. Shorten y T. M. Khoshgoftaar, "A survey on image data augmentation for deep learning," *J. Big Data*, vol. 6, art. 60, 2019, doi: 10.1186/s40537-019-0197-0.

[5] D. P. Kingma y J. Ba, "Adam: A method for stochastic optimization," en *Proc. 3rd Int. Conf. Learn. Represent. (ICLR)*, San Diego, CA, EE. UU., 2015.

[6] T. Fawcett, "An introduction to ROC analysis," *Pattern Recognit. Lett.*, vol. 27, no. 8, pp. 861–874, 2006.

[7] J. Elson, J. R. Douceur, J. Howell y J. Saul, "Asirra: A CAPTCHA that exploits interest-aligned manual image categorization," en *Proc. 14th ACM Conf. Comput. Commun. Secur. (CCS)*, Alexandria, VA, EE. UU., 2007.

[8] TensorFlow Datasets, "cats_vs_dogs." TensorFlow. https://www.tensorflow.org/datasets/catalog/cats_vs_dogs (consultado el 11 de oct. de 2026).

[9] M. Abadi *et al.*, "TensorFlow: A system for large-scale machine learning," en *Proc. 12th USENIX Symp. Oper. Syst. Des. Implement. (OSDI)*, Savannah, GA, EE. UU., 2016, pp. 265–283.

[10] C. Guo, G. Pleiss, Y. Sun y K. Q. Weinberger, "On calibration of modern neural networks," en *Proc. 34th Int. Conf. Mach. Learn. (ICML)*, Sídney, Australia, 2017, pp. 1321–1330.

[11] T. G. Dietterich, "Approximate statistical tests for comparing supervised classification learning algorithms," *Neural Comput.*, vol. 10, no. 7, pp. 1895–1923, 1998.

[12] L. Prechelt, "Early stopping but when?," en *Neural Networks: Tricks of the Trade*, G. B. Orr y K.-R. Müller, Eds. Berlín, Alemania: Springer, 1998, pp. 55–69.

[13] S. Ioffe y C. Szegedy, "Batch normalization: Accelerating deep network training by reducing internal covariate shift," en *Proc. 32nd Int. Conf. Mach. Learn. (ICML)*, Lille, Francia, 2015, pp. 448–456.

[14] M. Sandler, A. Howard, M. Zhu, A. Zhmoginov y L.-C. Chen, "MobileNetV2: Inverted residuals and linear bottlenecks," en *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, Salt Lake City, UT, EE. UU., 2018, pp. 4510–4520.

Anexo A. Evolución del entrenamiento cada 10 épocas

Valores de la primera semilla, como proporción entre 0 y 1.

Tabla 13: Accuracy de validación

Época	Denso	CNN	CNN2	Denso + AD	CNN + AD	CNN2 + AD
1	0,5383	0,6859	0,6807	0,5173	0,5483	0,5506
10	0,5790	0,7936	0,8392	0,5010	0,7297	0,7352
20	0,5790	0,7899	0,8318	0,5113	0,7770	0,7633
30	0,5887	0,7999	0,8381	0,5090	0,8151	0,8062
40	0,5901	0,7905	0,8303	0,5188	0,8257	0,8171
50	0,5749	0,7971	0,8464	0,5156	0,8343	0,8008
60	0,5222	0,8008	0,8415	0,5271	0,8601	0,8246
70	0,5818	0,7905	0,8421	0,5297	0,8469	0,8441
80	0,5801	0,7979	0,8300	0,5383	0,8607	0,8252
90	0,4961	0,7976	0,8389	0,5397	0,8664	0,8495
100	0,4976	0,7873	0,8386	0,5454	0,8808	0,8515

Tabla 14: Loss de validación

Época	Denso	CNN	CNN2	Denso + AD	CNN + AD	CNN2 + AD
1	0,6827	0,5973	0,6242	0,6947	0,6850	0,6811
10	0,6711	0,5623	0,4070	0,6923	0,5293	0,5355
20	0,6731	1,3130	0,6008	0,6903	0,4672	0,4987

30	0,6736	1,4131	0,7112	0,6911	0,4100	0,4244
40	0,6826	1,6811	0,8238	0,6920	0,3851	0,3984
50	0,7215	1,7086	0,7678	0,6911	0,3658	0,4326
60	0,7116	2,0576	0,8335	0,6913	0,3281	0,3794
70	0,7215	1,5162	0,9409	0,6894	0,3550	0,3547
80	0,7721	1,8951	0,8624	0,6870	0,3357	0,3830
90	0,6928	1,8616	0,9664	0,6855	0,3165	0,3452
100	0,6908	2,1774	0,9899	0,6858	0,2777	0,3389

Tabla 15: Capas de la CNN. La CNN2 agrega Dropout 0,5 antes del aplanado y usa Dense 250 (3.200.250 parámetros en esa capa; total 3.293.173).

Capa	Forma de salida	Parámetros
Entrada	100 x 100 x 1	0
Conv 3x3, 32 filtros, ReLU	98 x 98 x 32	320
MaxPooling 2x2	49 x 49 x 32	0
Conv 3x3, 64 filtros, ReLU	47 x 47 x 64	18.496
MaxPooling 2x2	23 x 23 x 64	0
Conv 3x3, 128 filtros, ReLU	21 x 21 x 128	73.856
MaxPooling 2x2	10 x 10 x 128	0
Aplanado	12.800	0
Dense 100, ReLU	100	1.280.100
Dense 1, sigmoide	1	101
Total		1.372.873

Anexo B. Reproducibilidad

- **Datos:** TensorFlow Datasets, *cats_vs_dogs* (versión 4.0.1), 23.262 imágenes tras el preprocesamiento.
- **Semilla:** 42, para la división de datos y el entrenamiento.
- **Entorno:** Google Colab con GPU y TensorFlow 2.21.0. El entrenamiento de los seis modelos sumó 124,3 minutos.
- **Código:** todas las tablas y figuras de este informe salen del notebook *Clasificador_perros_gatos_laboratorio*, que guarda además las tablas en CSV y las figuras en PNG.

Link del repositorio:

https://github.com/MarioAvilaSL/Clasificador_perros_gatos_laboratorio-redes-neuronales